Obliczenia rozproszone

Map-reduce

- map reduce - narzędzie kojarzone z Big Data, do przetwarzania danych na dużych klastrach obliczeniowych
- algorytm:
  - map - generujemy pary klucz-wartość
  - shuffle - przesyła pary o tym samym kluczu do jednego węzła
  - reduce - przetwarza otrzymane pary
- często przepisujemy zapytania SQL na map-reduce
- dzięki takiemu modelowi łatwo zaimplementować:
  - algorytmy zliczania słów/znaków w wielkich zbiorach tekstowych
  - język SQL
  - raporty podsumowujące transakcje w sklepie internetowym
- wady:
  - konieczność zapisu wyników pośrednich na dysk
  - sztywny format obliczeń w formie sekwencji par map-reduce

Bulk Synchronous Parallel

- abstrakcyjna idea, niepowiązana z konkretnym narzędziem
- cel - stworzenie systemu obliczeń:
  - równoległego
  - odpornego na awarie
  - wolnego od deadlocków
  - łatwego do prowadzenia wielkoskalowych obliczeń
- **supersteps**
  - w ramach jednego superkroku wykonywane jest mnóstwo równoległych obliczeń/procesów
  - gdy się wymienią wynikami to dopiero inicjowany jest kolejny superkrok
  - wcześniej bariera zatrzymuje procesy
- koszt kroku superstep:
  - $t_{\text{step}} = \max(w_i) + mg \max\{h_i\} + I$
  - w_i - czas pracy dla procesora i
  - h_i - liczba przychodzących i wychodzących wiadomości dla procesora i
  - m - rozmiar wiadomości
    - g - przepustowość danych do procesora
    - I - opóźnienie sieci

Pregel

- implementacja BSP od Googla
- wersja BSP dostosowana do przetewarzania w grafach
- obliczenia modelowane jako DAG (**Directed Acyclic Graph**)
- funkcje obliczane w węzłach
- cykle obliczeniowe - “supersteps”
- możliwa zmiana topologii grafu w trakcie obliczeń
- w każdej iteracji węzeł może:
  - odebrać wiadomość wysłaną w poprzedniej iteracji
  - wysłać wiadomości do innych węzłów
  - zmienić swój stan
  - zmodyfikować topologię grafu

DRYAD

- BSP od Microsofta
- proces obliczeniowy jako DAG
- struktura grafu może ewoluować w trakcie obliczeń (zmieniać się w trakcie liczenia)

GraphLab

- model obliczeń dedykowany problemom MLDM (*Machine Learning, Data Mining*)
- obliczenia składają się z grafu oraz tablicy klucz-wartość
- wyniki częściowe nie muszą być zapisywane na dysk
- dwa główne kroki:
  - *update* - obliczenia lokalne dla węzła i jego otoczenia
  - *sync* - agregacja wyników częściowych

Model Aktorowy

- cechy aktora
  - trwały
  - ma stan wewnętrzny
  - asynchroniczny
- ważna cecha układu - deterministyczny - aktor jest pasywny do czasu nadejścia wiadomości
- gdy przyjdzie wiadomość aktor może
  - wysłać skończoną liczbę wiadomości do innych aktorów
  - stworzyć skończoną liczbę innych aktorów
  - wybrać wywoływaną procedurę po otrzymaniu kolejnej wiadomości
- po awarii nadzorca może:
  - wznowić aktora zachowując stan
  - zrestartować go czyszcząc stan
  - zatrzymać jego działanie
  - eskalować błąd wyżej
- cechy jako model Big Data
  - zalety
    - niskopoziomowe zrównoleglenie - systemy z tysiącami aktorów
    - odporność na awarię - pojedynczy aktor nie blokuje całego systemu
    - dobrze nadaje się do modelowania przepływów i transformacji danych
    - elastyczne skalowanie
  - wady
    - szybko rośnie ilość komunikatów
    - trudne debugowanie
    - nieograniczone kolejki wiadomości mogą przeciążyć system
- przykłady - Akka, Erlang, Pulsar

Information Flow Processing (IFP)

DSMS

- *Data Stream Management Systems*
- porównanie z DBMS:
  - operują na strumieniach zamiast trwałych relacji
  - używają zapytań ciągłych zamiast jednorazowych
  - zakładają sekwencyjny dostęp i wysoką dynamikę napływu danych
  - często mają wymagania *real-time*

DSMS – Data Stream Management Systems

DBMS	DSMS
Persistent data (relations)	volatile data streams
Random access	Sequential access
One-time queries	Continuous queries
(theoretically) unlimited secondary storage	limited main memory
Only the current state is relevant	Consideration of the order of the input
relatively low update rate	potentially extremely high update rate
Little or no time requirements	Real-time requirements
Assumes exact data	Assumes outdated/inaccurate data
Plannable query processing	Variable data arrival and data characteristics

Table: DBMS vs DSMS

Active Databases

- posiada funkcjonalności typowej bazy danych
- identyfikuje nadejście nowego zdarzenia
- sprawdza warunki i uruchamia akcję
- posiada silnik uruchamiania reguł

CEP

- *Complex Event Processing*
- pozwala na przetwarzanie zdarzeń i reagowanie na nie
- odnajduje wzorce w sekwencjach zdarzeń
- możliwości filtrowania, agregacji
- śledzenie zależności między zdarzeniami (przyczynowe, czasowe itp.)

Model publish-subscribe

- model wymiany informacji między **luźno** powiązanymi usługami
- **brokerzy** pośredniczą w przekazywaniu wiadomości
- oddziela operację generowania informacji (wiadomości, zdarzenia, porcji danych itp.) od jej konsumpcji
- pozwala na przesyłanie danych w modelu wiele do wielu
- asynchroniczne działanie
- może stanowić bufor zwiększający odporność systemu na awarie komponentów
- **offset** - punkt ostatniego odczytu dla grupy konsumentów
  - przydatny do cofania się po awarii
  - przechowywany jest zwykle przez zarządcę modelu publish-subscribe
- przykład implementacji: Kafka
- rodzaje strumieni
  - *at-most once* - każda wiadomość zostanie dostarczona **co najwyżej raz** (jeżeli nie zostanie przetworzona, zostaje utracona)
  - *at-least once* - każda wiadomość zostanie dostarczona **co najmniej raz** (mogą pojawić się duplikaty gdy np. odbiorca nie potwierdzi odbioru)
  - *exactly once* - wiadomość zostanie dostarczona **dokładnie raz** (trudne do osiągnięcia w praktyce)

Inne modele i techniki

All-Pairs

- wzorzec obliczeń polegający na porównywaniu wszystkich elementów ze wszystkimi
- naiwnie ma bardzo wysoką złożoność i słabą skalowalność na dużych danych

Roaring Bitmaps

- skompresowana reprezentacja zbiorów liczb całkowitych
- pozwala wydajnie wykonywać operacje takie jak przecięcie, suma i filtrowanie
- przydatna przy indeksowaniu i analityce na dużych zbiorach

GPGPU

- wykorzystanie kart graficznych do obliczeń ogólnego przeznaczenia
- dobre dla operacji wykonywanych równolegle na dużych zbiorach danych
- typowe zastosowania:
  - przetwarzanie macierzy
  - uczenie maszynowe
  - symulacje

Graph Computing Systems

- systemy przetwarzania grafowego wykonują iteracyjne obliczenia na całym grafie
- bazy grafowe wspierają analizę online całego grafu lub jego fragmentów
- przykłady:
  - Apache Giraph
  - Neo4j

Przetwarzanie strumieni danych

- rekordy są przetwarzane pojedynczo lub w małych porcjach
- obliczenia definiuje się zwykle jako topologie DAG
- dla operacji stanowych trzeba śledzić stan obliczeń

Operacje

- bezstanowe
  - filtrowanie
  - mapowanie
- stanowe
  - agregacje
  - okna czasowe
- terminalne
  - zapis do bazy, pliku lub systemu zewnętrznego

Mikrobatch

- rekordy są przetwarzane małymi porcjami
- poprawia wydajność przy zachowaniu opóźnień zbliżonych do *real-time*

Unbounded table

- strumień można traktować jak nieograniczoną tabelę
- kolejne rekordy pojawiają się w niej na bieżąco